

Partiell integration

| Funktion        | Derivata         |
|-----------------|------------------|
| $g^a$           | $na^{n-1}$       |
| $a^x (a > 0)$   | $a^x \ln a$      |
| $\ln x (x > 0)$ | $\frac{1}{x}$    |
| $e^{ax}$        | $ka^{ax}$        |
| $\frac{1}{x}$   | $-\frac{1}{x^2}$ |

Om  $y = f(z)$  och  $z = g(x)$ , så är derivatan av  $y = f(g(x))$ :

$y' = f'(g(x)) \cdot g'(x)$

$$\int u(x) \cdot v'(x) dx = u(x) \cdot v(x) - \int u'(x) \cdot v(x) dx$$

| $k \cdot f(x)$      |  | $k \cdot f'(x)$                                      |
|---------------------|--|--|
| $f(x) + g(x)$       |  | $f'(x) + g'(x)$                                      |
| $f(x) \cdot g(x)$   |  | $f(x) \cdot g'(x) + f'(x) \cdot g(x)$ (Produktregel) |
| $\frac{f(x)}{g(x)}$ |  | $\frac{f'(x)g(x) - f(x)g'(x)}{(g(x))^2}$ (Kvotregel) |

**Föreläsning 3:**  
**Kvantiler:** det borde stå minus ett dvs **invers**  
p-quantil  $= F^{-1}(p)$  är det minsta värde av x där  $F(x) \geq p$   
Median:  $F^{-1}(0.5)$ , Nedre kvartil:  $F^{-1}(0.25)$ , Övre kvartil:  $F^{-1}(0.75)$ .  
**Funktion av en SV** **KAPITEL 3.8 SIDA 167**  
Fördelningen för X är känd men behöver hitta fördelning av  $Y = r(X)$

|   |  |  |
|---|--|--|
| DISKRET:<br>$Y = r(X)$ , $f(x)$ är PF för X, $g(y)$ är PF för Y: $g(y) = P(Y = y) = P(r(X) = y) = \sum_{x:r(x)=y} f(x)$ .<br>Summan av alla $f(x)$ för alla x-värden som uppfyller $r(x) = y$ . | KONTINUERLIG Y och X ( $Y=r(X)$ ) är en 1:1 funktion och deriverbar på X:s stöd (a,b) $\rightarrow$ Inversen $X=r^{-1}(Y) = s(Y)$ . CDF för Y: $G(y) = Pr(Y \leq y) = Pr(r(X) \leq y) = Pr\{X \leq s(y)\} = P\{X \leq s(y)\} = \sum_{x:s(x) \leq y} f(x)dx = F\{s(y)\} - F[a]$ . | $g(y) = f(s(y)) \cdot \left  \frac{d(s(y))}{dy} \right $ för $a < y < b$ . Alternativt (Ex): Derivera $G(y) = F(h(y)) \rightarrow G'(y) = f(h(y)) \cdot h'(y)$ .<br><b>Formel om linjärkomb:</b> $g(y) = \frac{1}{abs(b)} * f\left(\frac{y-a}{b}\right)$ |
|---|--|--|

**Föreläsning 7: MARKOV/CHEBY ÅR KAP 6 SIDA 248**  
**Markovs olikhet** är ett verktyg inom sannolikhets teori som ger en övre gräns för sannolikheten att en icke-negativ slumpvariabel X antar ett värde större än eller lika med ett givet tal t. För alla  $t > 0$ :  $Pr(X \geq t) \leq \frac{E(X)}{t}$ .  
**Chebychevs olikhet** är en sannolikhetsgräns som mäter hur stor sannolikheten att en slumpvariabel X avviker från sitt väntevärde E(X) med minst ett visst värde t. Den använder variansen Var(X) som mått på spridningen och gäller för alla fördelningar med ändlig varians. För alla  $t > 0$ :

|  |   |
|--|---|
| $P( X - E[X]  \geq t) \leq \frac{Var[X]}{t^2}$ | <b>ALT:</b> $Pr( X - E(X)  \geq kt) \leq \frac{1}{k^2}$ |
|--|---|

**Konvergens i sannolikheter:** En följd av slumpvariabler  $Z_1, Z_2, \dots$  konvergerar i sannolikheter mot ett värde b om för varje  $\epsilon > 0$ :  $\lim_{n \rightarrow \infty} Pr(|Z_n - b| < \epsilon) = 1$ . Tolkning: Ju större n blir, desto större sannolikhet att  $Z_n$  ligger inom ett godtyckligt litet intervall  $(b - \epsilon, b + \epsilon)$ . Notation:  $Z_n \xrightarrow{p} b$ . Om  $Z_n \xrightarrow{p} b$  och  $g(z)$  är en **kontinuerlig funktion** i punkten  $z = b$ , då gäller:  $g(Z_n) \xrightarrow{p} g(b)$ .  
**Konvergens i sannolikheter är svagare:** Den säger inget om hur snabbt  $Z_n$  närmar sig b, bara att sannolikheten ökar med n.  
**Stora talens lag** **Slumpmässigt stickprov:**  $X_1, \dots, X_n$  är oberoende och identiskt fördelade (i.i.d) från en fördelning med **ändligt medelvärde** ( $\mu = E(X_i)$ ) och **ändlig varians** ( $Var(X_i) < \infty$ ).  $\bar{X}_n = \frac{X_1 + \dots + X_n}{n} \xrightarrow{p} \mu$  när  $n \rightarrow \infty$ . Ju fler observationer (n) vi har, desto närmare kommer stickprovsmedelvärdet  $\bar{X}_n$  att ligga det sanna populationsmedelvärdet  $\mu$ .  
**Konvergens i sannolikheter** ( $\xrightarrow{p}$ ): Sannolikheten för att  $\bar{X}_n$  avviker från  $\mu$  med mer än en liten toleransnivå  $\epsilon$  går mot 0.  
**Centrals gränsvärdesatsen CLT:** För stora stickprov ( $n \rightarrow \infty$ ) är stickprovsmedelvärdet  $\bar{X}_n$  approximativt normalfördelat, även om populationen inte är normalfördelat. CLT gäller även för diskreta variabler (t.ex. binomiala, Poisson, eller enkla kategorier som myntkast). CLT säger att för alla x:  $\lim_{n \rightarrow \infty} Pr\left(\frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \leq x\right) = \Phi(x)$ , där  $\Phi(x)$  är fördelningsfunktionen för en standardnormalfördelning  $N(0, 1)$ . Approximativ normalfördelning:  $\bar{X}_n \approx N(\mu, \frac{\sigma^2}{n})$ .  
**OBS!** CLT gäller inte bara för stickprovsmedelvärden. T.ex. för summor av oberoende slumpvariabler  $S_n = \sum_{i=1}^n X_i \approx N(n\mu, n\sigma^2)$ .  
**OBS!** CLT förutsätter (i.i.d) data, **storlek på n** ( $n \geq 30$ ) och **väntevärde och varians existeras** men behövs ej vara kända.

**Föreläsning 5: VÄNTEVÄRDE: KAPITEL 4.1 SIDA 207**  
**Diskret SV:**  $E[X] = \sum_{\text{All } x} x f(x)$   
Väntevärde existerar endast om minst en av följande summor är ändlig:  $\sum_{\text{Positiva } x} x * f(x)$  eller  $\sum_{\text{Negativa } x} x * f(x)$ .  
**Kont SV** med pdf  $f(x)$ :  $E[X] = \int_{-\infty}^{\infty} x f(x) dx$ . Väntevärde existerar endast om **integralen konvergerar (dvs. inte går mot  $\pm\infty$ )**.  
**Väntevärde av en funktion (där Y = r(X))**  $E[r(X)] = \int_{-\infty}^{\infty} r(x) f(x) dx$   
**Väntevärde av en linjär funktion (Y=r(ax+b))**  $E[Y] = aE[X] + b$   
**GAUSS APPROXIMATION AV VÄNTEVÄRDE AV EN FUNKTION** **KAPITEL 4.1 SIDA 207**  
I allmänhet gäller inte  $E[r(X)] = r(E[X])$ . Gauss metod bygger på att **linjärisera r(X)** kring väntevärdet  $E[X]=\mu$ :  $r(X) \approx r(\mu) + r'(\mu)(X - \mu)$ , där  $r'(\mu)$  är derivatan av  $r(x)$  i punkten  $x = \mu$ .  $E[r(X)] \approx E[r(\mu) + r'(\mu)(X - \mu)] = r(\mu) + r'(\mu) * E[X - \mu]$ .  
Termen  $r'(\mu) * E[X - \mu]$  försvinner eftersom  $E[X - \mu] = 0 \rightarrow E[r(X)] \approx r(\mu) = r(E[X])$ . Den fungerar bra vid låg icke-linjärhet i r(X) och låg spridning i X:s fördelning.  
**Väntevärde av en produkt av oberoende variabler**  
Om  $X_1, \dots, X_n$  är oberoende SV med ändliga väntevärden gäller:  $E(\prod_{i=1}^n X_i) = \prod_{i=1}^n E(X_i)$ .  
**VARIANS**  
 $Var[X] = E[(X - \mu)^2] = E[X^2] - E[X]^2$   
 $Var[X] \geq 0$  och  $Var[X] = 0$  om och endast om  $P(X = c) = 1$  för en konstant c.  
**Varians av en linjär funktion (Y=aX+b)**  $Var[Y] = a^2 * Var[X]$   
Om  $X_1, \dots, X_n$  är oberoende slumpvariabler, och  $Y = a_1X_1 + \dots + a_nX_n + b$ , så gäller:  $Var(Y) = a_1^2 * Var(X_1) + \dots + a_n^2 * Var(X_n)$ .  
**GAUSS APPROXIMATION FOR A VARIANCE**  $Var[r(X)] \approx (r'(\mu))^2 * Var(X)$  (Derivera med avseende på X och sätt in  $r'$ )  
Detta underlättar beräkningar men kräver att funktionen är "tillräckligt linjär" nära  $\mu$  och  $Var(X)$  är liten.

|  |  |   |   |
|--|--|---|---|
| <b>Higher order moments, Skewness, Kurtosis</b> <b>KAPITEL 4.4 SIDA 234.</b> |  |   |   |
| Kth order moment:<br>$E[X^k]$  | Kth order central moment<br>$E[(X - \mu)^k]$<br>OBS k = 2 blir => Var[X] | Skevhet av en fördelning<br>$E[(X - \mu)^3]/\sigma^3$<br>+ <b>Positiv skevhet:</b> Höger svans är längre (fördelningen drar åt höger).<br>+ <b>Negativ skevhet:</b> Vänster svans är längre (fördelningen drar åt vänster). | Kurtosis (tugna svansar)<br>$E[(X - \mu)^4]/\sigma^4$<br>+ <b>Hög kurtos (&gt;3):</b> Tunga svansar och spetsig topp (t.ex. t-fördelning med få frihetsgrader).<br>+ <b>Låg kurtos (&lt;3):</b> Lättare svansar och plattare topp (t.ex. likformig fördelning). |

**Moment genererande funktion: KAPITEL 4.4 SIDA 234.**  
MGF är:  $\psi(t) = E(e^{tX})$   
 $E(X^n) = \psi^{(n)}(0)$  Användbar då moment är derivator av  $\psi(t)$  evalutat at  $t=0$ .  
MGF för linjär komb ( $Y=aX+b$ ):  $\psi_Y(t) = e^{bt} * \psi_X(at)$   
MGF för en summa:  $\psi_Y(t) = \psi_{X_1}(t) * \psi_{X_2}(t) * \dots * \psi_{X_n}(t)$ , där  $X_1, \dots, X_n$  är oberoende variabler och  $Y = X_1 + \dots + X_n$ .  
**MEAN, MEDIAN, MODE (MÅTT FÖR CENTRAL TENDENS (LAGESMÅTT) I EN FÖRDELNING S241 KAPITEL 4.5**  
Median:  $P(X \leq m) = 1/2$  (Delar fördelningen i 2 lika delar).  
Minimerar **absolut förlust:**  $E[|X - d|]$ .  
Mode  $X_{mode}$ : Det vanligaste värdet (maximerar sannolikhetstätheten  $f(x)$ ). Används för att identifiera "toppen" av fördelningen.  
Medelvärde (Mean): Genomsnittet av alla värden. Minimerar **kvadratisk förlust:**  $E[(X - d)^2]$ . Känsligt för extremvärden (stora avvikelser "straffas hårt").

**KOVARIAN**  $Cov(X, Y) = E[(X - \mu_X) * (Y - \mu_Y)] = E(XY) - \mu_X \mu_Y$ . Definieras som medelvärdet av produkten av avvikelserna från variablernas medelvärden som mäter **linjärt samband** mellan två variabler. **Positiv kovarians:** När X är över sitt medelvärde, tenderar Y också att vara över sitt. **Negativ kovarians:** När X är över sitt medelvärde, tenderar Y att vara under sitt.  
Linjärkombination:  $Var(aX + bY + c) = a^2 * Var(X) + b^2 * Var(Y) + 2ab * Cov(X, Y)$   
**Korrelation** (Korrelation mäter ENASTA linjära samband!). Variabler kan fortfarande vara beroende på ett icke-linjärt sätt (t.ex.  $Y = X^2$ ). Undantag: För normalfördelade variabler: **Nollkorrelation = Oberoende**.  
 $\rho_{X,Y} = \frac{Cov[X,Y]}{\sigma_X \sigma_Y}$  **FÖR BETINGAT VÄNTEVÄRDE KAPITEL 4.7 SIDA 256.**  
**Betingat väntevärde**  $E(Y|X) = \int_{-\infty}^{\infty} y * g_2(y|x) dy$ .  $g_2(y|x)$  är den betingade täthetsfunktionen för Y givet X=x.  
 $E(Y|X)$  är en funktion av X, inte av Y (har "integrerats bort" i  $E(Y|X)$ ). Eftersom X är en slumpvariabel  $\rightarrow E(Y|X)$  blir också en slumpvariabel.  
Law of iterated expectations:  $E[E(Y|X)] = E(Y)$ . **Tolkning:** Genom att först ta det betingade väntevärdet av Y givet X, och sedan ta väntevärdet över alla X  $\rightarrow$  Vi får det obetingade väntevärdet av Y.  
**Betingad varians:**  $Var(Y | X) = \int_{-\infty}^{\infty} (y - \mu_{Y|X})^2 * g_2(y | x) dy$  (Mäter spridningen av Y givet ett specifikt värde på X).  
**Total varians och dess uppdelning:**  $Var(Y) = E[Var(Y | X)] + Var[E(Y | X)]$ .  $E[Var(Y | X)]$ : Medelvärdet av de betingade varianserna (spridningen inom varje grupp av X).  $Var[E(Y | X)]$ : Variansen av de betingade medelvärdena (spridningen mellan grupper av X).  
**KOMMENTAR ÅNGÅENDE MOMENT GENERERANDE FUNKTION:** Om  $X_1, \dots, X_n$  är oberoende och identiskt fördelade (samma fördelning), och  $Y = X_1 + \dots + X_n$ , så är:  $\psi_Y(t) = \psi(t) * \dots * \psi(t)$  (n gånger) =  $[\psi(t)]^n$ . **OBS!** Id medför att  $\psi_{X_1}(t) = \psi_{X_2}(t) = \dots = \psi_{X_n}(t) = \psi(t)$ .

**Fördelning av en slumpvariabel (SV): KAPITEL 3.1 SIDA 91**  
• En kontinuerlig sv kan anta alla värden inom ett intervall (t.ex. tid, längd eller vikt).  
En diskret sv kan endast ta ett ändligt eller uppräknligt(countable) oändligt antal värden (t.ex. x1, x2, x3,...). **Kontinuerlig**  
**Kontinuerlig fördelning och PDF: KAPITEL 3.2 SIDA 100**  
För kont.sv gäller täthetsfunktion (Probability Density Function), tätheten  $\neq$  sannolikhet och har följande egenskaper:  
 $Pr(a \leq X \leq b) = \int_a^b f(x) dx$   
 $f(x) \geq 0$  för alla x  
 $\int_{(-\infty, \infty)} f(x) dx = 1$   
**KUMULATIV FÖRDELINGSFUNKTION (CDF) KAPITEL 3.3 SIDA 107**  
Defineras enligt (samma för kont/disk):  $F(x) = Pr(X \leq x)$  för  $-\infty < x < \infty$   
CDF är alltid kontinuerlig från höger:  $F(x) = F(x^+) = Pr(X \leq x)$   
Sannolikheter för intervall:  $P(x_1 < X \leq x_2) = F(x_2) - F(x_1)$   
**SAMBANDET MED KONT SV (PDF OCH CDF)**  
 $F(x) = \int_{(-\infty, x)} f(t) dt$  och konsekvent är  $f(x) = dF(x)/dx$   
**PDF OM VI HAR EN MARGINAL FÖRDELNING**  
Om  $f(x,y)$  är kontinuerlig bivarat fördelning (joint p.d.f) med stöd  $ex > 0$  och  $y > 0$ , och  $0 < 2x+y < 4$ . Om vi då vill få t.ex  $f(x)$  måste vi integrera med avseende på y (dy) där vi hade integrerat på stödet [0;4-2x].

**Föreläsning 4:**  
**Bivariat fördelning (joint dist)** **KAPITEL 3.4 SIDA 118**  
Är en samling av alla sannolikheter för händelser där både X och Y är inblandade.  
 $Pr\{X, Y \in C\}$  där C är en mängd av möjliga utfall (t.ex.  $X = 0$  och  $Y \geq 1$ ).  
**Diskret joint PF:**  $f(x, y) = P(X = x, Y = y)$  och  $\sum_{\text{All } x,y} f(x, y) = \sum_x \sum_y f(x, y) = 1$ .  
**Joint PDF:**  $P\{X, Y \in C\} = \iint_C f(x, y) dx dy$  där  $f(x, y) \geq 0$ . Sannolikheten av volymen under täthetsytan över regionen C.  
**Bivariat normal fördelning KOLLA FORMEL I BOKEN (s. 337)**  
**JOINT CDF:** Den kumulativa fördelningsfunktionen är:  $F(x, y) = P(X \leq x, Y \leq y)$   
Sannolikheter för rektangulära områden:  $P(a < X \leq b, c < Y \leq d) = F(b, d) - F(a, d) - F(b, c) + F(a, c)$   
 $F(x, y) = \int_{(-\infty, x)} \int_{(-\infty, y)} f(r, s) dr ds$ . Täthetsfunktionen  $f(x, y)$  är den andra partiella derivatan av  $F(x, y)$ :  $f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$   
**Marginalfördelning KAPITEL 3.5 SIDA 131**  
beskriver sannolikhetsfördelningen för en enskild variabel (t.ex. X eller Y) i en bivariat (tvådimensionell) fördelning. Den erhålls genom att "ignorera" eller sammanfatta den andra variabeln.  
 $f(x) = \sum_{\text{All } y} f(x, y)$  [DISKRET]

$f(x) = \int_{(-\infty, \infty)} f(x, y) dy$ ,  $F_1(x) = \lim_{y \rightarrow \infty} F(x, y)$  eller  $F_1(x) = \int_{(-\infty, \infty)} f(r, s) dr ds$  [KONTINUERLIG]  
**ÖBEROENDE VARIABLER** (kunskap om X ger ingen information om Y, vice versa). Två SV är oberoende om  $P(X \in A \text{ och } Y \in B) = P(X \in A) * P(Y \in B)$ . För kontinuerliga variabler kan oberoende även definieras via den gemensamma täthetsfunktionen om:  $f(x, y) = h_1(x) * h_2(y)$ , där  $h_1(x)$  och  $h_2(y)$  är täthetsfunktioner som enbart beror på x respektive y. **OBS!**  $h_1(x)$  och  $h_2(y)$  behöver inte nödvändigtvis vara marginalfördelningarna, men vid oberoende gäller  $h_1(x) = f_1(x)$  och  $h_2(y) = f_2(y)$ . Faktoriseringen  $f(x, y) = h_1(x) * h_2(y)$  kräver att stödet (området där  $f(x,y) > 0$ ) är rektangulärt (dvs. x och y varierar oberoende).  
**BETINGADE FÖRDELNINGAR (VART GIVET VAR2)** **KAPITEL 3.6 SIDA 141**  
Den betingade PDF av X givet  $Y=y_0$ :  $g_1(x|y) = \frac{f(x, y_0)}{f_2(y_0)}$  där  $g_1(x|y) dx = 1$   
Multiplikationsregeln  $f(x, y) = f_2(y) * g_1(x|y)$   
X och Y är oberoende om och endast om den betingade fördelningen för X sammanfaller med dess marginella fördelning:  $g_1(x|y) = f_1(x)$  för alla y där  $f_2(y) > 0$ .  
**FINN F(x) genom f(x) för kontinuerlig SV** - Om X är en SV med PDF f(x) och det frågas efter CDF. Då tar man integralen ex:  $F(x) = \int_0^x f(x) dx = \int_0^x \frac{t}{2} dt = \left[ \frac{t^2}{4} \right]_0^x = \frac{x^2}{4}$  och om  $F(X) = 0, x \leq 0, 0m F(X) = 1, x \geq 2$

**Beteckningar** Fördelningsfunktion - CDF gäller för både diskret och kontinuerlig.  
• Sannolikhetsfunktion (PF eller PMF) = Diskret  
• Täthetsfunktion (PDF) = Kontinuerlig

**Föreläsning 9:**  
**Sannolikhetsfunktio** beskriver hur data  $X_1, \dots, X_n$  genereras från en fördelning  $f(x|\theta)$  med kända parametrar  $\theta$  (t.ex.  $\mu$  och  $\sigma$  för normalfördelning). **Statistisk inferens** drar slutsatser om okända parametrar  $\theta$  utifrån observerade data  $x_1, \dots, x_n$  från  $f(x|\theta)$ .  
**Frekventist:** Parametrar (t.ex.  $\mu$  i en normalfördelning) ses som fasta konstanter. Sannolikhet definieras som den relativa frekvensen av en händelse vid många upprepningar. **Bayesian:** Parametrar kan tilldelas en sannolikhetsfördelning om deras värde är okänt. Sannolikhet är subjektiv och representerar en grad av tro (baserat på data och tidigare kunskap).  
**Likelihoodfunktionen:** Likelihoodfunktionen  $L(\theta|data)$  mäter hur troligt det är att observerad data uppstår för olika värden på en parameter  $\theta$ . **Likelihoodfunktionen är inte en pdf** för  $\theta$ . Likelihoodfunktionen  $L(\theta|x) = f(x|\theta)$  är samma matematiska uttryck, men den tolkas som en funktion av  $\theta$  (inte som en funktion av x). Integralen över  $\theta$  behöver inte vara 1:  $\int_{-\infty}^{\infty} f(x|\theta) d\theta \neq 1$  (i allmänhet).  
**INTRODUKTION TILL BAYES** Jag är osäker om  $\theta$ . Denna osäkerhet beskrivs av min subjektiva prior probabilitet distribution för  $\theta$ ,  $p(\theta)$ . Priorn beskriver min grad av tro givet olika värden för theta INNAN jag hämtar data. Jag samlar in min data  $X_1 = x_1, \dots, X_n = x_n$  från  $f(x_1, \dots, x_n | \theta)$ . Jag har då lärt mig om min posterior distribution  $f(\theta | X_1 = x_1, \dots, X_n = x_n)$  med avseende på  $\theta$ .  
**Bayes teori för dis.var och kont.var:**  $p(A|B) = \frac{p(B|A) * p(A)}{p(B)} = \frac{p(B|A) * p(A)}{p(B)}$ ,  $p(\theta | x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n | \theta) p(\theta)}{\int f(x_1, \dots, x_n | \theta) p(\theta) d\theta}$

En uppdaterad sannolikhetsfördelning för  $\theta$  efter att ha sett datan. Den kombinerar prior och data via **Bayes sats:**  $p(\theta|data) = \frac{p(data|\theta) * p(\theta)}{p(data)}$ . **Likelihood:**  $f(data|\theta)$  (hur troligt är data givet  $\theta$ ). **Prior:**  $p(\theta)$  (min initiala tro eller tidigare kunskap). **Marginal likelihood:**  $p(data) = \int f(data|\theta) * p(\theta) d\theta$  (En normaliseringskonstant). **Tolkning:** Posterior  $p(\theta|data)$  är en sannolikhets täthetsfunktion (pdf) för  $\theta$ , vilket innebär att  $\int p(\theta|data) d\theta = 1$ .  
**Prior:** Det är prior  $p(\theta)$  som hjälper konvertera likelihoodfunktionen till en posterior densitet för  $\theta$ .  
**Formel för posterior**

**Posterior  $\propto$  Likelihood \* Prior**  
 $p(\theta|x) \propto p(x|\theta) * p(\theta)$  där x är en vektor glöm ej det  
**EXEMPEL PÅ MOMENTMETODEN FÖR ATT SKATTA LAMBDA**  
**EXEMPLE**  
(X,Y) är SV, PDF:  $f(x, y) = \frac{3}{16} (4 - 2x - y)$  då  $x > 0, y > 0, 0 < 2x + y < 4$ . **A) Beräkna f(x):** För att göra detta finn integreringsområdet för  $y \Rightarrow 0 < y < 4 - 2x$ . Beräkna sedan följande integral  $\int_0^{4-2x} \frac{3}{16} (4 - 2x - y) dy$ . Detta ger då  $f(x) = 3/8(2-x)^2$ .  
**B) Bestäm f(Y|X):** Formeln för betingad p(x) säger  $f(X|Y) = \frac{f(x,y)}{f_2(y)}$  det vill säga  $\frac{3}{16} (4 - 2x - y) / \frac{3}{8} (x - 2)^2$  detta ger  $f(Y|X) = \frac{4-2x-y}{2(x-2)^2}$ .  
**C) Beräkna E[Y|X=1/2]:** Använda formel  $E[Y] = \int y f(y) dy$ . Ger  $\int y * \frac{1}{2} * \frac{(4-2(0.5)-y)}{2(0.5-2)^2} dy = \int \frac{1}{9} (3 - y) dy, 0 < y < 3 \dots = 1$   
**UPPGIFT 2:** Låt X ha PDF  $f(x) = 2x, 0 < x < 1$  Bestäm PDF för  $Y = 1 - X^2$ . Så använda formel  $P(Y \leq y) = P(X \leq \sqrt{y-1}) = F_X(\sqrt{y-1})$ . Derivera nu mha kedjeregeln. Så först deriverar vi  $F_X$  som yttre derivatan och sedan y-1 som inre. Det ger  $\frac{dF_X(y)}{dy} = f_X(\sqrt{y-1}) = 2\sqrt{y-1}$  = yttre derivatan och  $\frac{d\sqrt{y-1}}{dy} = \frac{1}{2\sqrt{y-1}} * (1) =$  inre derivatan. Sedan skriv ut hela uttrycket med  $f(x) = 2(\sqrt{y-1}) * \frac{1}{2\sqrt{y-1}} = \frac{2\sqrt{y-1}}{2\sqrt{y-1}} = 1$  Detta är Ys PDF.  
**EXEMPEL UPPGIFT:** Låt SV X ha PDF  $f(x) = \theta x^{\theta-1}$  där  $0 < x < 1$  annars 0.  
Beräkna  $E[X] = \int_0^1 x * \theta x^{\theta-1} dx = \frac{\theta}{\theta+1}$

**Medianen för X:**  $P(X < m) = 0.5$  där  $m = \text{medianen } P(X < m) = \int_0^m \theta x^{\theta-1} dx = m^{\theta} = 0.5 \Rightarrow m = 0.5^{\frac{1}{\theta}}$   
**EXEMPEL GAUSS APPROXIMATION:** Låt  $X_1$  och  $X_2$  vara oberoende och exponentialfördelade med lambda = 3.  
**Visa att  $6(X_1 + X_2)$  är approximelat med två frihetsgrader:** Använd mfg för exp  $\psi_X(t) = \frac{1}{\lambda - t}$  Där  $Z = 6(X_1 + X_2)$ ,  $\psi_Z(t) = E[e^{it^6(X_1+X_2)}] = \dots = E[e^{it^6X_1}] E[e^{it^6X_2}] = \psi_{X_1}(t^6) \psi_{X_2}(t^6) = \left( \frac{\lambda}{\lambda - t^6} \right)^2 = \dots (\lambda = 3) = \left( \frac{3}{3 - t^6} \right)^2 = (1 - 2t^6)^{-2}$  vilket är  $\chi^2(4)$   
Beräkna  $E\left[\frac{2}{X_1 + X_2}\right]$  mha gauss approximation:  $X_1 + X_2$  är gamma(2,3) så  $E[X_1 + X_2] = 2/3$  det vill säga  $E[2/(X_1 + X_2)] = 2/(2/3) = 3$

Formel för m.g.f.:  $\psi_X(t) = E(e^{itX}) = \int_{-\infty}^{\infty} e^{itx} f(x) dx$  (kontinuerlig X),  
 $\psi_X(t) = E(e^{itX}) = \sum_{-\infty}^{\infty} e^{itx} p(x)$  (diskret X).

**Inverse CDF-metoden** Om  $Y \sim U(0,1)$  och F är en kontinuerlig CDF av  $X$ , så kan vi generera X med fördelning F genom att sätta  $X = F^{-1}(Y)$ . Generera först  $u_1, \dots, u_n \stackrel{iid}{\sim} U(0,1)$ . Beräkna sedan  $x_i = F^{-1}(u_i)$ . Då blir  $x_1, \dots, x_n \stackrel{iid}{\sim} F$ . (Det innebär att om F är normalfördelningens CDF  $\rightarrow x_1, \dots, x_n$  är normalfördelad). Metoden kan anpassas för diskreta slumpvariabler, men kräver extra hantering eftersom CDF:en är styckvis konstant. Ex: För att simulera X ~ Binomial(n, p), leta upp det minsta x där  $F(x) \geq u$  för ett givet  $u \sim U(0,1)$ .  
**Föreläsning 13 - Pivotal kvantitet:** En statistisk variabel/funktion av stickprovsdata och parametern  $\theta$  vars känd fördelning inte beror på okända parametrar (här  $\mu$  eller  $\sigma^2$ ).





